

详解xgboost算法的样本不平衡问题

原创 石头 机器学习算法那些事 2019-01-18

XGBoost官方文档对参数scale_pos_weight的定义：

```
scale_pos_weight [default=1]
```

- Control the balance of positive and negative weights, useful for unbalanced classes.
- A typical value to consider $\text{sum}(\text{negative instances}) / \text{sum}(\text{positive instances})$

翻译：

调节正负样本权重的平衡，常用来处理不平衡的正负样本数据。

典型值算法：

scale_pos_weight = 负样本总数/正样本总数。若训练负样本总数是500，正样本总数100，那么设置scale_pos_weight为5。

scale_pos_weight的含义：

字面意思是正样本权重尺度，是一个关于调节正样本权重的变量。好吧，让我们[深入XGBoost的源码分析](#)：

源码：

```
for (omp_ulong i = n - remainder; i < n; ++i)
{
    auto y = info.labels_[i];
    bst_float p = Loss::PredTransform(preds_h[i]);
    bst_float w = info.GetWeight(i);
    w += y * ((param_.scale_pos_weight * w) - w);      # 权重更新方程
    gpair[i] = GradientPair(Loss::FirstOrderGradient(p, y) * w,
                            Loss::SecondOrderGradient(p, y) * w);
}
```

我们重点关注权重更新方程那一行，可得如下[结论](#)：

当 $\text{scale_pos_weight} > 1$ 时，即训练集的负样本总数大于正样本总数， y 表示类别，由权重更新方程可知，正类对应的权重 w 增加，负类对应的权重不变。同理可知 $\text{scale_pos_weight} < 1$ 时的权重更新。

讲到这里，是不是觉得参数 scale_pos_weight 的内容已经讲完了？其实不是，xgboost官方文档对定义又加了如下补充：

For common cases such as ads click through log, the dataset is extremely imbalanced. This can affect the training of XGBoost model, and there are two ways to improve it.

- If you care only about the overall performance metric (AUC) of your prediction
 - Balance the positive and negative weights via scale_pos_weight
 - Use AUC for evaluation
- If you care about predicting the right probability
 - In such a case, you cannot re-balance the dataset
 - Set parameter max_delta_step to a finite number (say 1) to help convergence

翻译：

常见的情况比如广告点击日志，数据集是极其不平衡的，导致训练的xgboost模型受到影响，有两种方法可以改善：

- 1) 如果仅仅关注预测问题的AUC指标，那么你可以调节 scale_pos_weight 参数来帮助训练数据不平衡带来的收敛问题。
- 2) 如果关注预测概率的准确性问题，那么你就不能调节 scale_pos_weight 参数来改变样本权重的方法帮助收敛，可通过设置参数 max_delta_step 为一个有限的值来帮助收敛。

说一说我对这两种方法的理解：

如果仅仅关注AUC指标，那么我们可以调节参数 `scale_pos_weight`，因为改变 `scale_pos_weight` 并没有改变AUC值，假设我们预测四个人是正样本的概率分别是：0.2,0.4,0.6,0.8，调节该参数后预测四个人是正样本的概率分别是0.3,0.6,0.7,0.9，根据AUC的计算公式，调节参数前后的AUC并没有改变，但是样本的预测概率却发生改变了。因此，调节参数 `scale_pos_weight` 改变了预测概率，并没有改变AUC指标。

也可以通过贝叶斯的角度去理解第二种方法中不能改变权重的原因：

[例] 训练数据集有1000个正常人，100个癌症病人，假设不改变权重，利用贝叶斯思想预测测试样本是正常人的先验概率大约是0.9，癌症病人的先验概率大约是0.1。若大大增加癌症病人的权重，有可能导致测试样本是正常人和癌症病人的先验概率都是0.5，这完全不符合现实情况。因此，改变权重导致了预测概率的不可信问题。

参考

https://xgboost.readthedocs.io/en/latest/tutorials/param_tuning.html

<https://xgboost.readthedocs.io/en/latest/parameter.html>

<https://blog.csdn.net/h4565445654/article/details/72257538>

推荐阅读

XGBoost算法原理小结

XGBoost参数调优小结

浅谈频率学派和贝叶斯学派

